

# 基于 GIS 的网约车乘客安全状态监测模型研究\*

钱 振<sup>1</sup> 周 侗<sup>1,2,▲</sup> 马培龙<sup>1</sup> 陶 菲<sup>1</sup> 刘 浩<sup>1</sup>

(1. 南通大学地理科学学院 江苏南通 226007; 2. 南京师范大学虚拟地理环境教育部重点实验室 南京 210023)

**摘 要:** 为提供网约车乘客及时可靠的救险援助, 防范网约车司机侵害乘客案件的再度发生, 研究基于“潜在危险区域”的多参数安全状态监测模型。从地理时空角度, 分析案件发生的区域和时间特征, 基于其时空规律, 提取城市“潜在危险区域”, 构建车辆 OD 距离、异常速度、行驶时间等因子, 同时结合乘客信息, 实时综合分析乘客安全状态。以南通市港闸区为例, 以出租车轨迹、兴趣点、OSM 开源路网以及城市影像等作为实验数据, 实验结果表明, 模型能够有效监测出车辆在“潜在危险区域”内行驶时车辆的异常行为, 当不设立“潜在危险区域”时, 模型能够准确地识别出司机的异常驾驶, 如绕行、异常停止等, 实验精度达到 92.06%, 其中绕行判别精度为 90.57%, 异常停止判别精度为 100%, 证明研究的模型能够取得较好的监测效果。

**关键词:** 交通安全; 网约车安全; 乘客安全状态监测; 时空分析; 犯罪地理

中图分类号: U491 文献标志码: A doi:10.3963/j.issn.1674-4861.2019.04.005

## A Detection Method for Passenger Safety Based on GIS

QIAN Zhen<sup>1</sup> ZHOU Tong<sup>1,2,▲</sup> MA Peilong<sup>1</sup> TAO Fei<sup>1</sup> LIU Hao<sup>1</sup>

(1. School of Geographic Science, Nantong University, Nantong 226007, Jiangsu, China;

2. Key Laboratory of Virtual Geographic Environment of Ministry of Education, Nanjing Normal University, Nanjing 210023, China)

**Abstract:** In order to provide timely and reliable rescue assistance for the passengers use car-hailing, and prevent recurrent cases that passengers are infringed by online car-hailing drivers, a multi-parameter model based on “potential danger zone” for safety state monitoring is studied. From a perspective of geographical space-time, regional and temporal characteristics are analyzed. Based on its spatial-temporal regular pattern, “potential danger zone” of one city is extracted, and factors such as OD distance of vehicle, abnormal speed, and driving time are constructed. Safety statuses of passengers are comprehensively analyzed in real time with passengers’ information. Taking Gangzha District of Nantong as a case study, the data of trajectories of taxis, points of interest, OSM open source road network, and urban image are analyzed. The results show that the model can effectively monitor abnormal behaviors of vehicles in “potential danger zone”. When there is no “potential danger zone”, the model can accurately identify abnormal driving of online car-hailing drivers, such as detour, abnormal stop, etc. Experimental accuracy is 92.06%. The accuracy of bypass discrimination is 90.57%, and that of abnormal stop discrimination is 100%, which proves that the model can achieve better monitoring effect.

**Key words:** traffic safety; safety of online car-hailing; passenger safety status monitoring; spatial-temporal analysis; geography of crime

收稿日期: 2019-02-15

\* 国家自然科学基金项目(41301514)资助

第一作者简介: 钱 振(1997—), 本科生, 研究方向: 时空数据挖掘。E-mail: 1152327161@qq.com

▲通信作者: 周 侗(1978—), 博士, 副教授, 研究方向: 智能交通, 地理信息技术。E-mail: tonggis@163.com

## 0 引言

在“互联网+”蓬勃发展的背景下,“网约车”的出现极大地便利了人们的生活,成为我国城镇居民的主要出行方式之一。但由于“网约车”行业入门门槛低、发展速度快、其业内工作者综合素质良莠不齐,使得车辆安全管理较为困难,从业人员的违法行为在一定程度上易逃脱法律制裁,导致违法犯罪现象屡禁不止,乘客安全难以得到保障。

目前,学者们主要集中于探讨政府部门、立法与司法机关等主体在管理上的改进,却疏忽了交通位置、地理环境和计算机技术的结合<sup>[1-2]</sup>。随着移动通信技术与GPS/BDS定位技术的快速发展,海量的交通移动轨迹数据开始涌现,基于车辆移动轨迹数据的时空挖掘方面研究逐渐增多。

在网约车方面,崔航等<sup>[3]</sup>建立出行需求系统动力学模型,模拟居民出行需求的变化。邵春福等<sup>[4]</sup>从顾客满意角度出发,基于主成分分析与BP神经网络评价网约车服务质量。Afeche等<sup>[5]</sup>通过构建空间网络,匹配乘客需求和司机服务能力,平衡车辆供需。Dias<sup>[6]</sup>等通过数据融合,分析并预测多种乘车目的的旅行频率。Xia等<sup>[7]</sup>结合LSTM模型和GBDT模型,预测用户请求乘车的意图。Sun等<sup>[8]</sup>基于空间自回归滑动均值模型挖掘城市交通道路排放情况。

在车辆安全监测方面,杨龙海等<sup>[9]</sup>设计基于GPS数据的车辆异常行为分级检测算法,识别车辆异常行为。Zhou等<sup>[10]</sup>研究了一种在线异常轨迹检测方法,以改善出租车服务。Chen等<sup>[11]</sup>使用在线方法,实时识别并检测异常轨迹。Song等<sup>[12]</sup>基于递归神经网络捕获异常行驶轨迹。Wang等<sup>[13]</sup>提出基于编辑距离和层次聚类的轨迹聚类方法,监测出租车异常轨迹。Krishnamurthy等<sup>[14]</sup>使用自然语言处理模型对目标运动的时空模式进行分类,并检测异常的行为轨迹。

尽管基于移动轨迹的时空挖掘研究类型广泛,但基于网约车安全类研究鲜有开展。网约车安全监测是一个综合性的复杂研究,需结合犯罪地理学、人文地理学和交通运输学等对车辆行驶轨迹进行分析,并对城市特定区域进行划分,可一定程度上达到个性化监管<sup>[15]</sup>,因此,本文研究基于“潜在危险区域”的多参数安全状态监测模型,对实时的车辆轨迹数据进行行为分析,监测其行驶中异常行为,并结合多个因子和危险区域进行

综合危险评分,在实际需求中选取合理参数,使模型更加智能化、人性化,为相关部门的监管提供参考,为居民的安全出行保驾护航。

## 1 乘客安全状态监测模型建立

### 1.1 模型背景

犯罪行为与时空因素高度相关,往往会集中在一个高发时期及某些热点空间区域,且该类区域的人口密度、经济情况,以及区域类别等有着显著的特征<sup>[16]</sup>,因此,基于时空规律预测犯罪行为意义重大。本文根据实际网约车司机犯罪的时空特征<sup>[17]</sup>,构建出“潜在危险区域”,其定义为城市中人口稀少(低活力地区)、分布偏远(非建成地区)、周围空旷(山林、建筑用地)或曾发生过乘客遭迫害案件的区域,其中对于人口稀少、分布偏远和周围空旷等具体区域可根据监管需求和实际情况进行规范。数据显示,在不同时段内网约车司机发生犯罪的比例不同,从而将1d分为案件高发段、潜在危险段、安全段等3个时段<sup>[17]</sup>。基于此,针对不同时段的危险区域赋予相应危险系数,以达到城市区域合理的监管。

车辆轨迹描述了当前行驶的状态,不仅可用于交通监控预测<sup>[18]</sup>、个性化路线推荐<sup>[19]</sup>、行车路线选择<sup>[20]</sup>,在司机异常行驶行为监测也有一定作用<sup>[21-23]</sup>。针对乘客安全状态的监测,本文将利用大数据分析技术选取合适的模型因子,并结合潜在危险区域进行综合分析,当车辆行驶于潜在危险区域内,将实时计算订单的危险积分。结合网约车司机侵害乘客案件的特殊性,本模型包含了对乘客性别及数量信息的处理,即当乘客为女性且数量较少时,乘车安全性将降低,从而可有效地提供安全保障。

### 1.2 模型因子选取

基于大数据分析技术,挖掘出车辆不同订单OD频度规律,以此选取模型较优因子,其中OD频度规律是指车辆基于相同的起始位置和终点位置的不同订单路线的频度规律,频度高的路线为正常行驶路线,频度低的路线可能存在司机异常行驶行为,如绕路等<sup>[10-11]</sup>。

本文使用南通市2018年1536万条出租车订单数据进行OD频度分析(见图1),分析频度较低的订单轨迹的时空规律。经分析,该类订单的时间和距离因素均高出正常行驶的订单,且具有一定的规律性,并考虑到网约车案件的特殊性,

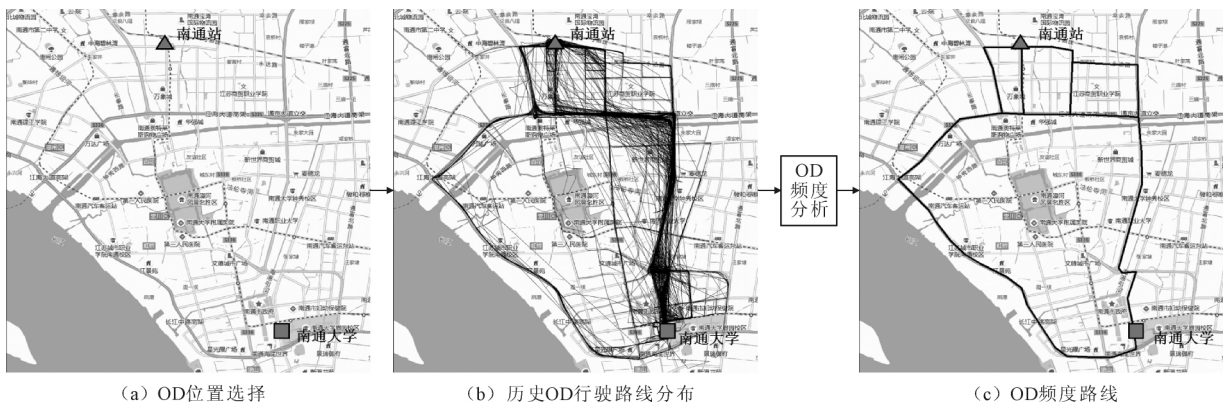


图 1 OD 频度分析示意图  
Fig. 1 OD frequency analysis diagram

如停车作案等特征,因此,将以车辆 OD 距离、异常速度以及行驶时间作为模型因子。

1.3 模型构建

结合多项综合因子,构建了多参数的安全状态监测模型,通过计算车辆实时的危险积分  $P_{总}$  以判断当前的乘车安全性。

$$P_{总} = W \times D_i \times \sum_{i=1}^L \theta_i \times P_i \tag{1}$$

式中: $D_i$  为潜在危险区域的危险指数; $P_j$  为各项因子的危险积分; $W$  为乘客安全系数; $P_{总}$  为总危险积分; $\theta_i$  为  $P_j$  的权重; $L$  为 3 模型结构,见图 2。

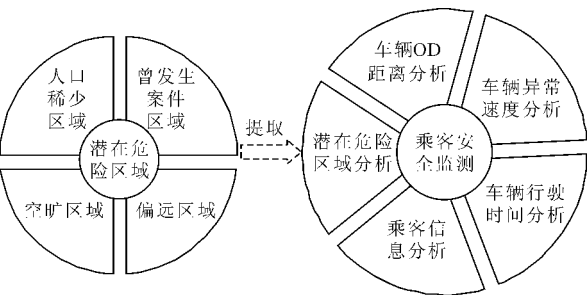


图 2 模型结构示意图  
Fig. 2 Model structure diagram

2 模型因子分析

在本模型中,分析车辆在潜在危险区域行驶时的行为轨迹和乘客信息,给予相应的危险积分,通过总危险积分  $P_{总}$  的大小监测车辆中乘客们的安全状况。具体分析步骤如下。

2.1 潜在危险区域

潜在危险区域的划分步骤如下。

1) 根据城市中不同时段的安全状况,分为案件高发段  $T_1$ 、潜在危险段  $T_2$ 、安全段  $T_3$ 。

2) 根据 POI 数据和不同时段的城市车辆上下客点构建低热力区域,对其进行分类并赋予密

度较大的区域以危险指数  $D_1$ 。

3) 提取城镇非建成区,赋予危险指数  $D_2$ 。

4) 将步骤 2) 和 3) 的结果数据进行交集运算,交集结果作为偏远区域  $Sp_1$ ,对应区域危险指数叠加。

5) 通过提取建设工地以及山林地区作为空旷区域  $Sp_2$ ,并赋予危险指数  $D_3$ 。

6) 对于曾经发生过相关案件或被投诉的地区,以点集  $P_i$  描述,并以其为中心建立半径为  $r$  的缓冲区,为案件高发区  $Sp_3$ ,并赋予危险指数  $D_4$ 。

7) 合并  $Sp_1$ ,  $Sp_2$  和  $Sp_3$ ,危险指数相应叠加,危险指数不为 0 的地区即为潜在危险区域  $S$ 。

8) 不同时间段潜在危险区域的危险程度将会变化,在案件高发段内,危险指数统一提升  $I_1$ ;潜在危险段内,危险指数统一提升  $I_2$ ;安全段内不变。见式(2)。

$$D_i | T_1 = I_j + D_i \tag{2}$$

式中: $D_i | T_j$  为  $T_j$  时间段  $i$  区域的危险指数为  $D_i$ ,  $j=1$  或 2。

“危险程度指数”作为潜在危险区域评价体系的基础,可根据案件常发生的区域特征赋予相应指数<sup>[24]</sup>,见表 1,以区别偏远区域、空旷区域和案件高发区域的不同危险程度。

表 1 潜在危险区域评分示例

Tab. 1 Example of potential danger zone scoring		
类型	要素	细分危险指数(1~20)
偏远区域	非建成区	3
	低活力区	5
空旷区域	山林区域	7
	工地区域	13
案件高发区域	被投诉区域	19
	曾发生案件区域	20

2.2 车辆 OD 距离

长期以来,网约车服务中普遍存在乘客被一

些司机绕行并多收费的典型现象,特别是在不熟悉的区域行驶时,乘客可能无法识别该类异常行为。对于这种现象,可对实时车辆轨迹进行研究,分析当前已行驶的路线,并与 OD 频度较高的路线进行对比<sup>[22-23]</sup>,以此判断司机是否存在绕路行为。

对于此类研究,本模型将针对案件特性,结合潜在危险区域进行分析。当车辆在危险区域行驶时,若当前位置与目的地的距离没有减小趋势,反而大于前 1 个轨迹点与目的地的距离,当距离差超过一定阈值时,对其进行危险评定,具体方法如下。

1) 初始化车辆当前订单的危险积分  $P_1$  为 0,处于“距离增加状态”的标志  $dis\_flag$  为 0。

2) 当车辆行驶进入潜在危险区域时,计算车辆当前位置点  $Pos_i(n)$  与目的地位置点  $Des(n)$  的实时距离  $S(Pos_i(n), Des(n))$  为

$$S(Pos_i(n), Des(n)) = \sqrt{(Des(n)_x - Pos_i(n)_x)^2 + (Des(n)_y - Pos_i(n)_y)^2} \quad (3)$$

式中: $n$  是订单的序号; $i$  是订单  $n$  的轨迹点序号。

3) 判断  $S'$  是否大于 0,若大于 0,令  $dis\_flag$  为 1,并判断距离差  $\Delta S$ ,当  $\Delta S$  超过阈值  $X$  时,每增加  $n_1$  m,则更新危险积分  $P_1$  为  $P_1 + 1$ 。其中  $S'$  和  $\Delta S$  计算见式(4)~(5)。

$$S' = \frac{dS(Pos_i(n), Des(n))}{dt} \quad (4)$$

$$\Delta S = S(Pos_i(n), Des(n)) - S(Pos_{i-1}(n), Des(n)) \quad (5)$$

式中: $S'$  大于 0 时, $S(Pos_i(n), Des(n))$  则增加。

### 2.3 车辆速度异常

GPS 数据中的速度信息能够直接反映出车辆的当前状态,通过速度变率、速度大小可直接鉴别车辆行驶状态,当车辆速度较高或速度变率较大时司机会存在异常驾驶行为<sup>[21-23]</sup>。在以往的网约车司机侵害乘客案件中,司机会选择停车作案<sup>[17]</sup>,此时,GPS 会记录当前的车辆速度状态,因此,判断订单过程的异常停车行为至关重要。

本模型将车辆的异常停止定义为车辆速度异常,即不因等红灯或堵车而停车且时间过长,超过一定阈值时,则判定该行为为异常行为,对其进行危险评定,具体方法如下。

1) 初始化当前订单的危险积分  $P_2$  为 0,处于“停车异常状态”的标志  $stop\_flag$  为 0。

2) 车辆在危险区域行驶时,若速度为 0,分析实时路况拥堵状况和交通灯等待状况,判断此时

车辆是否处于拥堵或等红灯状态,即车辆数据是否落入拥堵路段和交通灯缓冲区内,若均否,令  $stop\_flag$  为 1。

3) 当  $stop\_flag$  等于 1 时,停止时间超过阈值  $Y$  时,每隔  $n_2$  秒,更新危险积分  $P_2$  为  $P_2 + 1$ 。

在实际应用中,考虑到司机倾向在处于“载客模式”时进行交接班及短暂休息,会产生“停止状态”的订单行为,可能导致危险积分过高。对于此情形,需对数据源进行处理,当乘客数量为 0 时(即 APP 未传输乘客数据至服务器)当前订单不计入评分。




图3 道路拥堵示意图

Fig. 3 Road congestion diagram

### 2.4 车辆行驶时间

司机异常驾驶行为不仅表现在 OD 路径上,也可在时间上进行感知,结合车辆轨迹当前位置和时间进行时空分析,将实际路径行进时间与最短路径行进时间进行对比也可鉴别出车辆的异常行为<sup>[25]</sup>。

在模型中,当车辆已行驶时间超过 OD 预计时间,且时间差超过一定阈值时,则判断该行为属于异常行为,对其进行危险评定,具体方法如下。

1) 初始化当前订单的危险积分  $P_3$  为 0,处于“时间异常状态”的标志  $time\_flag$  为 0。

2) 通过百度地图提供的批量算路 API 计算 OD 预计时间  $T_p$ 。

3) 计算已行驶时间  $T_r$ ,并计算行驶时间差  $\Delta T$ ,当  $\Delta T$  大于 0 时,令  $time\_flag$  为 1。其中  $T_r$  计算见式(6)。

$$T_r = time_r - time_o \quad (6)$$

式中: $time_r$  为当前时间; $time_o$  为初始地出发时间。

4) 当  $time\_flag$  为 1 时,计算  $\Delta T$ ,若  $\Delta T$  大于阈值  $T_s$ ,每隔  $n_3$  秒,则更新积分  $P_3$  为  $P_3 + 1$ 。

其中  $\Delta T$  计算见式(7)。

$$\Delta T = T_r - T_p \tag{7}$$

2.5 乘客信息

以往网约车案件的受害者大都是女性乘客，且车内乘客较少<sup>[17]</sup>，乘客性别和人数与案件发生概率有较强的相关性<sup>[24]</sup>，因此，结合乘客的信息进行分析至关重要。在本模型中，将针对乘客性别和人数，给予适当的危险评定系数，具体方法如下。

1) 初始化乘客危险系数  $W_c$  为 0，“乘客性别”标志  $sex\_flag$  为 0。

2) 使用自主研发的手机 APP 获取乘客的人数  $count(count \geq 1)$  和性别，当全为女性时令  $sex\_flag$  为 1，令  $W_c$  为 1。

3) 当  $sex\_flag$  为 1 时，每增加 1 位乘客危险系数减  $wc_i(1 \leq i \leq 3)$ ，令  $W_c$  为  $W_c - wc_i$ 。

以上因子反映了订单实时的综合状况，在使用时可通过灵活调整参数以适应不同的监管需求和城市特性，从而可提高监测效率。

3 案例分析

3.1 实验样区及数据

南通市港闸区地势平坦，土地肥沃，空间上毗邻上海，拥有优越的地理位置和交通条件。该地区功能分区多为城乡结合部，本文提出的“潜在危险区域”在该地区样例较多，便于实验开展。

3.1.1 车辆轨迹数据

实验数据来自江苏省南通市出租车北斗/GPS 监控平台，基于南通市从 2018 年 12 月 1 日—30 日的出租车运营数据，包含有车牌号、轨迹时间、坐标、方向、瞬时速度和运营状态等信息。

获取的出租车轨迹数据存在着一些异常情况，如：时间越界、定位误差、数据格式错误等，需进行剔除错误信息，位置纠偏，筛选订单数据等预处理<sup>[26]</sup>。部分处理后的轨迹数据见表 2，其中 LON 为经度，LAT 为纬度，ORDER 为订单序号，TYPE 为轨迹点类型。

3.1.2 兴趣点数据

实验数据为包含住宅、学校、美食、医院、景区和小区等关键字 POI 数据，其中包含了 XY 坐标、兴趣点名称和关键字等信息。

3.1.3 城市路网及其拥堵状况数据

实验数据使用 OSM 开源路网一级道路数据，其属性包括道路名称、几何类型等。结合网络爬虫和百度地图提供的实时路况查询接口，以及

表 2 部分处理后轨迹数据记录  
Tab. 2 Partially processed trajectory data record

车牌号	时间	速度/ (km/h)	LON /(°)	LAT /(°)	ORDER	TYPE
苏 FB <sup>xxxx</sup>	2018-12-01 T00:05:22	24.4	120.937 6	31.923 6	1	上客点
苏 FB <sup>xxxx</sup>	2018-12-01 T00:05:35	0	120.937 4	31.923 7	1	
⋮	⋮	⋮	⋮	⋮	⋮	⋮
苏 FB <sup>xxxx</sup>	2018-12-01 T00:32:41	55.8	120.854 3	32.018 6	1	
苏 FB <sup>xxxx</sup>	2018-12-01 T00:33:11	18.4	120.853 9	32.019 3	1	下客点

阿里云云服务器，从 2018 年 12 月 1 日 0 点—2019 年 1 月 1 日 0 点，获取实时道路状况。参照百度地图标准，其中状态代码为 1 代表畅通，车辆能够快速行驶；2 代表缓行，车辆速度减缓，但没有停止；3 代表拥堵，车辆出现拥堵状况；4 代表严重拥堵，车辆难以行驶。由于 http 请求并返回数据有一定延迟性，从而使得拥堵状况数据中的时间不是整点，需将其进行修正。对数据进行批量处理，时间处理后的道路拥堵状况数据见表 3。

表 3 部分处理后拥堵数据记录  
Tab. 3 Partially processed congestion data record

时间	道路名称	状态代码	状态
2018-12-04 T15:30	工农路	2	缓行
2018-12-04 T16:00	工农路	1	畅通
2018-12-04 T16:30	工农路	1	畅通
2018-12-04 T17:00	工农路	1	畅通
2018-12-04 T17:30	工农路	3	拥堵

3.1.4 城市影像数据

实验数据中珞珈一号夜光遥感数据来自高分辨率对地观测系统湖北数据与应用网下载的 2018 年 10 月 29 日影像；Landsat-8 OLI 影像数据为从地理空间数据云下载的 2017 年 12 月影像，原始数据包含 12 个波段，云量为 0.46%，分辨率为 30 m。

3.2 实验过程

3.2.1 潜在危险区域提取

车辆轨迹数据和 POI 数据分别描述了动静态的城市活力特征，为了区分城市内不同地区的活力程度，通过客运车辆的上下客点和 POI<sup>[27]</sup> 分别进行核密度分析，并将其分成高、低密度区域，以此提取人口稀少区域。

近年来，众多学者通过夜光遥感数据提取城镇建成区，进行城市扩张、GDP 发展水平<sup>[28]</sup> 等研究。本文基于灯光强度越强是城镇建成区的可能性越高的假设，使用二分法设置阈值，并通过与统

计数数据对比以不断调整阈值,最终提取出非建成区<sup>[29]</sup>,作为城市中的偏远区域。利用 Landsat-8 OLI 影像数字化提取出山林、建筑用地,作为城市中的空旷区域。对以上提取出的区域赋予危险指数,并进行合并,将相应位置危险指数叠加,最终提取出  $T_1$ 、 $T_2$  和  $T_3$  时段的潜在危险区域(本文中,  $T_1$  为 00:00—06:00,  $T_2$  为 15:00—24:00,  $T_3$  为 06:00—15:00<sup>[17]</sup>),见图 4。




图 4 各时段潜在危险区域

Fig. 4 Potential danger zone map in each time period

### 3.2.2 因子参数选取

本文针对 OD 距离、速度异常和行驶时间等因子的参数选取,选择 12 月 12 日中可能存在异常行为(司机绕远路和停止时间过长)的订单为实验数据,开展多组实验对比不同参数对因子结果的影响。

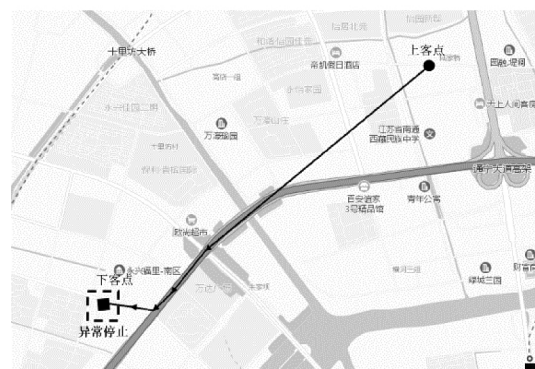
研究使用南通市出租车管理系统提取可能存在绕路、异常停止行为的订单(见图 5),基于该数据,分别采用不同参数计算各因子危险积分,不同结果对比见图 6。针对存在异常行为的订单,模型各因子危险积分的计算结果能较好反映车辆实时状态。为了准确反映乘客实时安全状态,在保证危险积分数值适中且能精确反映实时轨迹的状态的前提下,本文选择的各因子较优参数(见表 4),其中 OD\_DIS 为 OD 所需路程。

### 3.2.3 总危险积分计算

提取港闸区内所有的订单数据,并以不同的订单作为实验对象,选择较优参数,使用模型脚本对其进行批量运算,得到车辆实时的危险积分。本文使用层次分析法赋予各因子危险积分权重,



(a) 绕路行为



(b) 异常停止行为

图 5 存在异常行为的订单轨迹

Fig. 5 Order trajectory with abnormal behavior

表 4 安全分析部分结果

Tab. 4 Safety analysis part results

因子	参数	较优值
OD 距离	$X$	$OD\_DIS/15$
	$n_1$	$X/6$
速度异常	$Y$	60
	$n_2$	9
行驶时间	$T_s$	$T_p * 2$
	$n_3$	$T_p/10$

其权重分别为 0.3, 0.44 和 0.26。当轨迹点在危险区域内时,赋予轨迹当前行驶区域的潜在危险指数,因研发的 App 未投入使用,本文基于乘客为单独女性(即  $sex\_flag$  为 1)的情况计算综合危险积分  $P_{总}$ ,部分结果见表 5。

表 5 部分综合评分

Tab. 5 Part comprehensive Score

车牌号	时间	type	$P_{总}$
苏 FB****	2018-12-23 T02:02:48	上客点	0
苏 FB****	2018-12-23 T02:05:03		0
苏 FB****	2018-12-23 T02:05:19		0
苏 FB****	2018-12-23 T02:05:49		0
苏 FB****	2018-12-23 T02:06:19		0
苏 FB****	2018-12-23 T02:06:50		0.117
苏 FB****	2018-12-23 T02:07:20		5.512
苏 FB****	2018-12-23 T02:07:49		7.956
苏 FB****	2018-12-23 T02:08:20	下客点	9.945




图 6 各因子危险积分结果对比  
Fig. 6 Comparison of various factors' risk scores

3.3 实验分析

针对实验结果进行分析,其中, $T_2$  时段订单数量较多,且该时段内的危险积分普遍高于  $T_1$  和  $T_3$  时段,甚至个别订单的危险积分是其他订单的几十倍。通过对危险积分较高的订单进行追踪,该订单大部分时刻的  $P_1$  和  $P_3$  积分较高,反映该订单在模型中的距离和时间因素存在异常,可能存在绕路行为<sup>[23]</sup>,且某些时刻行驶在潜在的危险区域内,最终导致模型计算的总积分较高,见图 7。此外,节假日期间的危险积分普遍低于工作日,由于居民出行量增加,直接造成了订单数量增多,司机发生不法行为的概率降低,从而乘车安全性显著提升,一定程度上证明了该监测模型的可靠性。

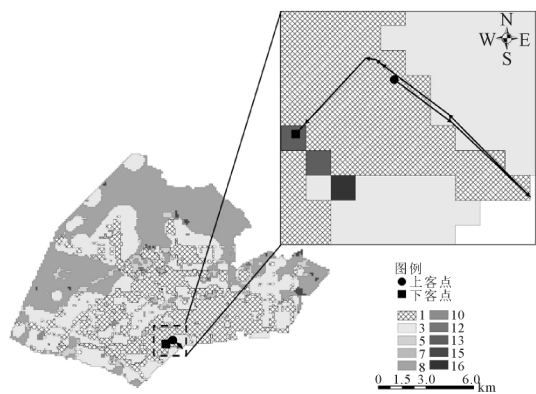


图 7 危险积分较高的车辆轨迹  
Fig. 7 Vehicle trajectory with higher risk scores

3.4 结果检验

因实验数据均不存在乘客遭受侵害的样例,在该部分将不设立“潜在危险区域”,综合使用各因子评判车辆的异常行为。基于  $P_{总}$  数值对订单进行降序排序,选取前 0.5% 高的 63 个订单,并利用出租车管理系统以及基于大数据的 OD 频度

分析方法对其轨迹进行判别,最终判别出有 58 个订单存在异常行为,如绕行、异常停止等,实验精度可达到 92.06%,其中异常停止行为判别精度为 100%,绕行行为判别精度为 90.57%,部分结果见表 6。其中,大部分车辆的  $P_2$  较低,从而反映出车辆异常停止的次数较少,然而仍有部分订单该积分较高,本文在实际中对  $P_{总}$  较高且  $P_2$  较高订单的司机进行访谈,发现如果红灯时间过长将会导致得分偏高,对此情况需要根据城市交通特点调整模型参数。

表 6 模型检验  
Tab. 6 Model checking

车牌号	订单开始时间	订单结束时间	$P_{总}$ 最大值	行为类型
苏 FB****	2018-12-02 T16:16:33	2018-12-02 T16:22:05	43.794	正常
苏 FB****	2018-12-03 T15:13:35	2018-12-03 T15:27:14	137.482	绕行
苏 FB****	2018-12-05 T15:59:57	2018-12-05 T16:17:20	89.685	绕行
苏 FB****	2018-12-09 T07:11:59	2018-12-09 T07:26:13	104.843	绕行
⋮	⋮	⋮	⋮	⋮
苏 FB****	2018-12-23 T17:00:18	2018-12-23 T17:37:34	91.702	异常停止
苏 FB****	2018-12-23 T07:50:30	2018-12-23 T08:03:30	228.634	绕行

因模型基于百度地图 API 在理想条件下计算 OD 预计时间,缺乏考虑城市交通的实际情况,如道路拥堵、道路建设状态等,导致部分计算结果明显小于实际所需时间,从而导致模型结果具有一定的误差。

4 结束语

本文从地理时空角度研究了“网约车”乘客的安全监测,提出了基于“潜在危险区域”的多参数

安全状态监测模型。结合多方面因素提取出城市中潜在的危險区域,基于大数据分析选取模型因子,结合多组实验分析选取较优参数,并利用时空行为分析车辆订单的实时轨迹行为,实验结果表明模型的监测效果较好。但在实际应用中,受轨迹点的位置精度、百度地图 API 计算精度影响,导致模型监测仍存在一定误差,在后续的工作中需解决数据带来的影响,同时也需考虑实际的复杂交通状况,以减少评分误差。

### 参考文献

### References

- [1] 马竞遥. 共享经济模式下网约车管理立法研究[J]. 山东社会科学, 2018(9):148-153.  
MA Jingyao. Research on the legislation of network car management under the shared economy model [J]. Shandong Social Sciences, 2018(9):148-153. (in Chinese)
- [2] 柴彦威. 中国时空行为研究进展[J]. 地理科学进展, 2013, 32(9):1362-1373.  
CHAI Yanwei. Progress in space-time behavior research in China[J]. Progress in Geography, 2013, 32(9):1362-1373. (in Chinese)
- [3] 崔航, 李书峰, 王维才. 网约车需求对城镇居民出行的影响研究: 以北京市为例[J]. 城市发展研究, 2017, 24(5):1-4.  
CUI Hang, LI Shufeng, WANG Weicai. Research on impact of the internet car-hailing demand on private travel: a case study of Beijing[J]. Urban Development Studies, 2017, 24(5):1-4. (in Chinese)
- [4] 邵春福, 王菁, 彭金栓. 基于主成分分析和 BP 神经网络的网约车服务质量评价[J]. 北京交通大学学报, 2018, 42(3):10-15.  
SHAO Chunfu, WANG Jing, PENG Jinshuan. Internet private hire vehicle service quality evaluation based on principal component analysis and BP neural network[J]. Journal of Beijing Jiaotong University, 2018, 42(3):10-15. (in Chinese)
- [5] AFECHÉ P, LIU Z, MAGLARAS C. Ride-hailing networks with strategic drivers: the impact of platform control capabilities on performance [J]. Columbia Business School Research Paper, 2018(18/19):18-19.
- [6] CONTRERAS S D, PAZ A. The effects of ride-hailing companies on the taxicab industry in Las Vegas, Nevada[J]. Transportation Research Part A: Policy and Practice, 2018(115):63-70.
- [7] XIA Y, ZHOU J, CAO J, et al. Intent-aware audience targeting for ride-hailing service[C]. Joint European Conference on Machine Learning and Knowledge Discovery in Databases, Dublin, Ireland: Springer, Cham, 2018.
- [8] SUN D J, ZHANG K, SHEN S. Analyzing spatio-temporal traffic line source emissions based on massive didi online car-hailing service data[J]. Transportation Research Part D: Transport and Environment, 2018(62):699-714.
- [9] 杨龙海, 徐洪, 张春. 基于 GPS 数据的高速公路车辆异常行为检测[J]. 重庆交通大学学报(自然科学版), 2018, 37(5):97-103.  
YANG Longhai, XU Hong, ZHANG Chun. Vehicle abnormal behavior detection on freeway based on global positioning system data [J]. Journal of Chongqing Jiaotong University(Natural Science Edition), 2018, 37(5):97-103.
- [10] ZHOU Z, DOU W, JIA G, et al. A method for real-time trajectory monitoring to improve taxi service using GPS big data [J]. Information & Management, 2016, 53(8):964-977.
- [11] CHEN C, ZHANG D Q, LI N, et al. iBOAT: Isolation-based online anomalous trajectory detection. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(2):806-818.
- [12] SONG L, WANG R, XIAO D, et al. Anomalous trajectory detection using recurrent neural network [C]. International Conference on Advanced Data Mining and Applications, Nanjing, China: Springer, Cham, 2018.
- [13] WANG Y, QIN K, CHEN Y, et al. Detecting anomalous trajectories and behavior patterns using hierarchical clustering from taxi GPS data[J]. ISPRS International Journal of Geo-Information, 2018, 7(1):25.
- [14] KRISHNAMURTHY V, GAO S. Syntactic enhancement to VSIMM for roadmap based anomalous trajectory detection: A natural language processing approach[J]. IEEE Transactions on Signal Processing, 2018, 66(20):5212-5227.
- [15] 孙晨星, 周侗, 盖宸德, 等. 面向社区矫正的敏感区域行为分析方法[J]. 地理与地理信息科学, 2018, 34(3):114-118, 124.  
SUN Chenxing, ZHOU Tong, GE Chende, et al. Behavior analysis method based on the sensitive region theory oriented to community correction mo-



- monitoring[J]. Geography and Geo-Information Science, 2018,34(3):114-118,124. (in Chinese)
- [16] ASHBY M P, BOWERS K J. A comparison of methods for temporal analysis of aoristic crime[J]. Crime Science,2013,2(1):1.
- [17] 最高人民法院. 司法大数据专题报告之网络约车与传统出租车服务过程中犯罪情况[EB/OL]. (2018-09-21)[2018-01-24]. <http://www.court.gov.cn/fabu-xiangqing-120431.html>. Supreme People's Court. Crimes in internet taxi appointment and traditional taxi service in special report on judicial big data[EB/OL]. (2018-09-21)[2018-01-24]. <http://www.court.gov.cn/fabu-xiangqing-120431.html>. (in Chinese)
- [18] WILLIAMS B. Multivariate vehicular traffic flow prediction; Evaluation of ARIMAX modeling[J]. Transportation Research Record; Journal of the Transportation Research Board,2001(1776):194-200.
- [19] LIU L, XU J, LIAO S S, et al. A real-time personalized route recommendation system for self-drive tourists based on vehicle to vehicle communication[J]. Expert Systems with Applications, 2014,41(7):3409-3417.
- [20] KONG X, LI M, Tang T, et al. Shared subway shuttle bus route planning based on transport data analytics[J]. IEEE Transactions on Automation Science and Engineering,2018,15(4):1507-1520.
- [21] AL-DOHUKI S, WU Y, KAMW F, et al. SemanticTraj: A new approach to interacting with massive taxi trajectories[J]. IEEE Transactions on Visualization and Computer Graphics,2016,23(1):11-20.
- [22] LIU L, ANDRIS C, RATTI C. Uncovering cab-drivers' behavior patterns from their digital traces[J]. Computers Environment & Urban Systems, 2010,34(6):541-548.
- [23] LIU S, NI L M, KRISHNAN R. Fraud detection from taxis' driving behaviors[J]. IEEE Transactions on Vehicular Technology,2014,63(1):464-472.
- [24] 韩 娟.“网约车”领域相关犯罪问题研究[J]. 法制与社会,2017(28):48-49.  
HAN Juan. Research on related crimes in the field of "Online Car-appointment" [J]. Legal System and Society,2017(28):48-49. (in Chinese)
- [25] 郭 闯,陈文静,王均瑶. 长春市轨道交通与空间及业态的联动关系研究[J]. 交通运输研究,2018,4(1):35-43.  
GUO C, CHEN W J, WANG J Y. Linkage relationship of rail transit, space parameters and formats in Changchun[J]. Transport Research,2018,4(1):35-43. (in Chinese)
- [26] 周 林,马晓凤,钟 鸣. 基于出租车 GPS 数据的城市次干道阻抗函数研究[J]. 交通信息与安全,2017,35(3):34-42.  
ZHOU Lin, MA Xiaofeng, ZHONG Ming. A study on impedance function of city secondary road based on taxi GPS data[J]. Journal of Transport Information and Safety, 2017, 35 (3): 34-42. (in Chinese)
- [27] 罗孝羚,蒋阳升. 基于出租车运营数据和 POI 数据的出行目的识别[J]. 交通运输系统工程与信息, 2018,18(5):60-66.  
LUO Xiaoling, JIANG Yangsheng. Trip-purpose-identification based on taxi operating data and POI data[J]. Journal of Transportation Systems Engineering and Information Technology, 2018, 38 (23):8536-8543. (in Chinese)
- [28] SHI K, HUANG C, YU B, et al. Evaluation of NPP-VIIRS night-time light composite data for extracting built-up urban areas[J]. Remote Sensing Letters,2014,5(4):358-366.
- [29] HE C, LI J, CHEN J, et al. The urbanization process of Bohai Rim in the 1990s by using DM-SP/OLS data[J]. Journal of Geographical Sciences,2006,16(2):174-182.